Fergio Harjanto - 2802392412

I. Bagian A: Analisis Konseptual (Bobot: 20%)

II. Efek Regularisasi pada Batch Normalization (Slide 6–8)

A. Mekanisme statistik mini-batch yang menimbulkan efek regularisasi berasal dari stochastic noise yang dimasukkan ke dalam layer activation, melalui mini-batch statistics. Dropout meng-regularize sebuah model dengan menambahkan binary noise, dimana batch norm menambahkan gaussian noise melalui batch statistic yang disample secara random

B. Kondisi/skenario ketika asumsi menghilangkan dropout tidak berlaku contohnya jika;
   - Ketika ukuran mini-batch yang sangat kecil, estimasi batch variance akan sangat tidak stabil dan menjadi terlalu ekstrim, sehingga merusak stabilitas convergence
   - Penggunaan dropout dan batch normalization pada saat yang bersamaan

III. Degradasi Jaringan Dalam dan Formulasi Residual

Secara teoritis, model dengan layer yang lebih banyak seharusnya sama saja dengna model yang layernya sedikit, melalui identity mapping (Output = Input) seharusnya bisa meng-setting layer extra untuk diam saja. Namun, tiap layer memiliki fungsi aktivasi seperti relu, yang akan men-distort hasil output, dan dalam CNN dengan layer banyak, distortion tersebut akan menumpuk terus dan menyebabkan training accuracy turun.

A. Skip connection mengubah formulasi aliran gradient saat backpropagation dengan menyediakan jalan pintas, yang melewatkan (meng-skip) beberapa layer dan meng-feed output satu layer sebagai input the beberapa layer selanjutnya (tidak hanya 1 selanjutnya).

B. Vanishing gradient terjadi saat gradien mengecil ketika backpropagation. Perkalian beruntun pada backprop sangat rentan turun ke 0 jika magnitudo weight nya kecil (eigenvalue < 1) atau jika ReLU menghasilkan nilai 0. Jika dikalikan oleh puluhan layer, akan medekati 0. Skip connection dapat membantu mitigasi vanishing gradient dengan shortcutnya, dengan menyediakan jalan alternatif yang tidak menurunkan nilai gradient

IV. Feature Extraction vs Fine-Tuning
Perbandingan:

	Feature extraction	Fine tuning
Jumlah parameter	Hanya lapisan klasifikasi akhir	½ lapisan atas sampai seluruh parameter model
Volume training data	Rendah	Menengah - tinggi
Beban compute & memory per epoch	Rendah, fitur bacbone dihitung satu kali	Tinggi akibat backprop
Resiko destructive gradient update	Tidak ada, karena seluruh weights dibekukan	tinggi

- Feature extraction digunakan apabila volume data target terbatas dan kemampuan kapasitas compute dan memori rendah, serta data training mirip dengan data pre-training model.
- Fine-tuning digunakan apabila volume data besar, kapasitas compute dan memori lebih tinggi, serta data training berbeda jauh dengan data pre-training model.

V. Kaidah Penerapan Data Augmentation

A. Data augmentation hanya diaktifkan pada train set karena test set dan validation set adalah set yang digunakan untuk menjadi tolak ukur performa generalisasi model pada distribusi data dunia nyata. Jika augmentation dilakukan, pada test/validation set, maka set tersebut akan tercemar dan mengubah hasil evaluasi model, sehingga angka hasil evaluasi tidak bisa dipercaya. contohnya, model bisa saja meng-generalize dengan sangat bagus, tetapi karena test/val set tercemar akibat augmentation, ketika diuji, hasilnya jelek dan tidak merepresentasikan dunia nyata

B. Contoh transformasi yang tidak layak adalah seperti color inversion. Warna, apalagi pada bulu dan pola pada sebuah hewan bisa menjadi sebuah feature yang sangat penting untuk membedakan satu ras dari ras lainnya. Jika rona warna khas sebuah hewan berubah, maka akan merusak invariansi semantik label karena perubahan tersebut mengubah identitas visual ras menjadi tidak realistis atau menyerupai ras yang berbeda

VI. Mitigasi Catastrophic Forgetting
   A. Fenomena catastrophic forgetting bisa terjadi ketika sebuah neural-network diberikan data baru, NN tersebut bisa meng over-adjust weight dalam dirinya untuk data yang terbaru tersebut, sehingga knowledge dari weight lama digantikan oleh knowledge dari data baru.
   B. Strategi mitigasi catastrophic forgetting:
      1. Differential learning rate: penerapan value learning rate yang berbeda di layer yang berbeda, contohnya, backbone menerima value rendah dan layer atas menerima value tinggi. secara teoritis, backbone value rendah akan merubah weightsnya dengan perlahan, sehingga model lebih stabil terhadap data baru yang sangat berbeda dengan weight lama
      2. Data replaying: menggabungkan contoh-contoh data dari set lama, ke dalam data training baru. Secara teoritis, sangat membantu, karena masalah catastrophic forgetting adalah melupakan pengetahuan data lama. Dengan menambahkan data lama kembali, akan mengurangi kesempatan untuk catastrophic forgetting terjadi

VII. Bagian B: Eksperimen Praktik (Bobot: 40%)
Eksperimen di Colab dapat diakses disini

VIII. Bagian C: Laporan dan Analisis (Bobot: 35%) (Ada di PDF Laporan Teknis, akibat keterbatasan halaman)
   1. Tabel Konsolidasi dan Visualisasi Pembelajaran
   2. Pembahasan Analisis Komparatif
   3. Failure Analysis (Analisis Kasus Misklasifikasi)
   4. Rekomendasi Rekayasa dan Batasan Eksperimen
   5. Eksplorasi Tambahan (Nilai Tambah / Opsional)

Fergio Harjanto - 2802392412

Pernyataan Penggunaan AI

- AI digunakan untuk membantu dalam pembuatan tugas ini
- Gemini 3.8 Flash melalui Antigravity CLI digunakan untuk iterasi kode notebook, debugging, serta membantu penalaran research paper yang digunakan untuk dijadikan jawaban pada analisis konseptual (Bagian A)
- Output AI diverifikasi secara mandiri, seperti;
    - Memverifikasi kode bekerja seharusnya dengan melihat documentation, memverifikasi berjalan secara mulus, tanpa adanya disconnect runtime pada Google Colab, dan memverifikasi output data satu cell konsisten dengan cell lainnya.
    - Memverifikasi bahwa penjelasan research paper benar-benar tertulis pada papernya sendiri.

Primary Sources

https://arxiv.org/abs/1801.05134
https://arxiv.org/abs/1512.03385
https://arxiv.org/abs/2509.08255
https://arxiv.org/abs/1412.1710
https://arxiv.org/abs/2202.10054v1
https://arxiv.org/abs/1801.06146
https://arxiv.org/abs/1706.02677
https://arxiv.org/abs/1612.00796
https://arxiv.org/abs/1411.1792
https://journalofbigdata.springeropen.com/articles/10.1186/s40537-019-0197-0
https://arxiv.org/abs/1603.05027
https://arxiv.org/abs/1502.03167

https://discovery.ucl.ac.uk/id/eprint/10061069/1/samplepaper.pdf

Additional Sources

https://apxml.com/courses/cnns-for-computer-vision/chapter-6-advanced-transfer-learning-domain-adaptation/fine-tuning-feature-extraction-advanced
https://share.google/AJk8C0oR1C5ohgbZ
https://stackoverflow.com/questions/48029542/data-augmentation-in-test-validation-set
https://www.ibm.com/think/topics/catastrophic-forgetting
https://www.ultralytics.com/glossary/catastrophic-forgetting

Fergio Harjanto - 2802392412

https://apxml.com/courses/fine-tuning-adapting-large-language-models/chapter-5-advanced-fine-tuning-strategies/mitigating-catastrophic-forgetting
https://www.ibm.com/think/topics/learning-rate
https://theaisummer.com/skip-connections/#skip-connections-for-the-win
https://stackoverflow.com/questions/78277395/freeze-some-layers-in-resnet