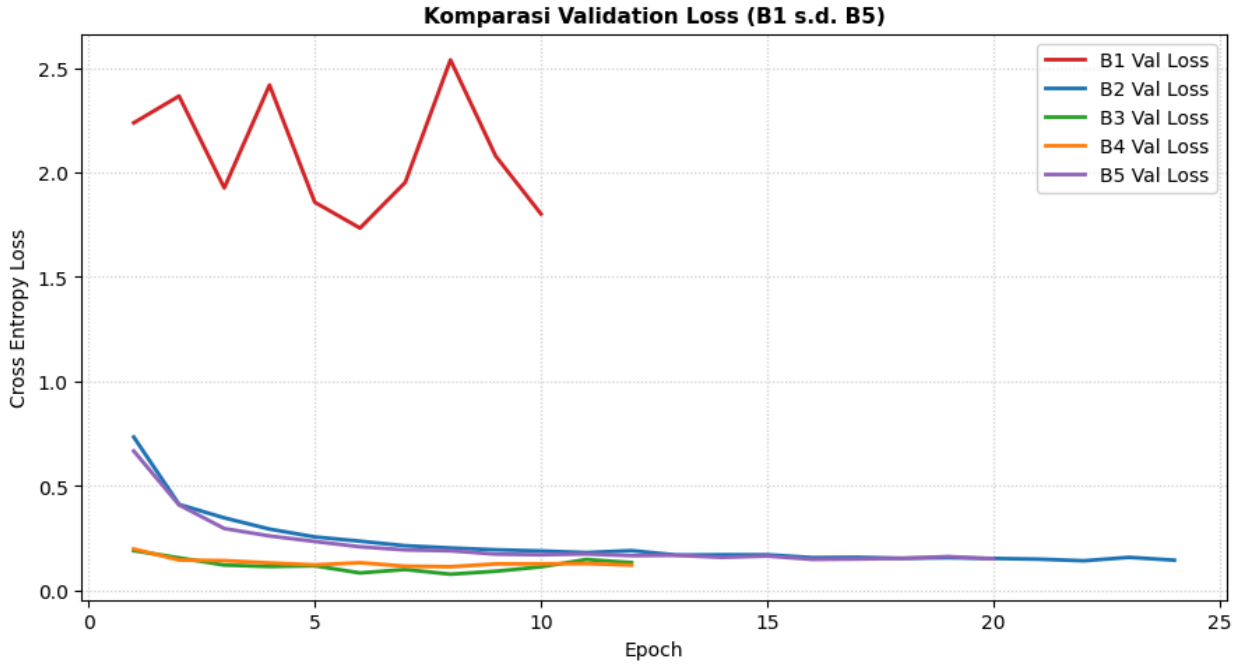
Fergio Harjanto - 2802392412

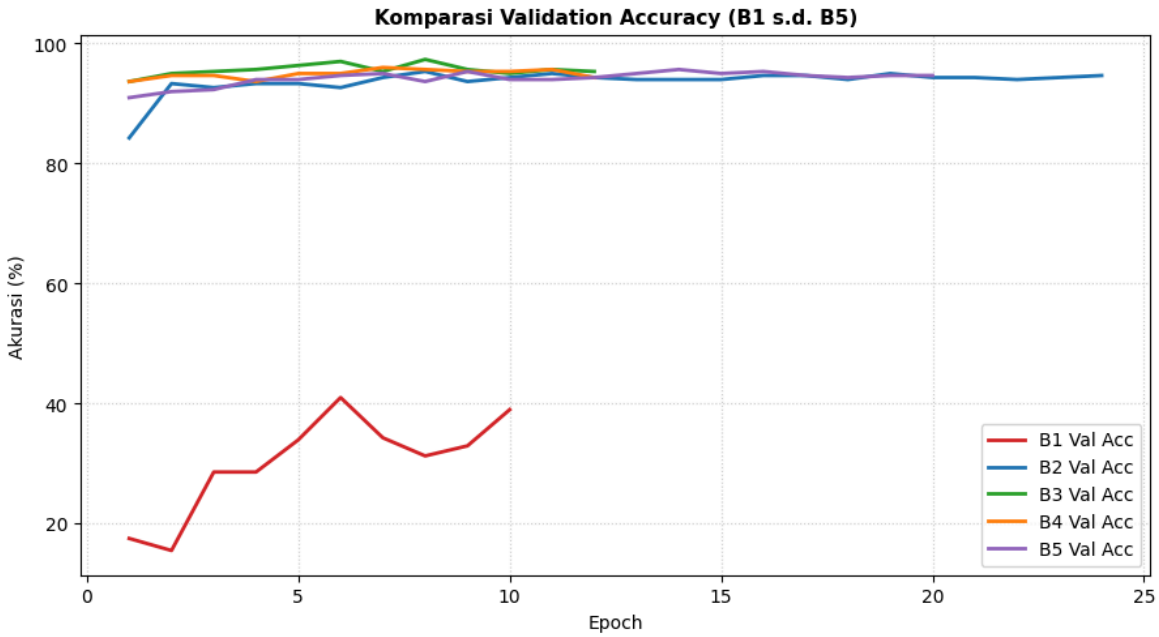
I. C1 - Tabel Konsolidasi dan Visualisasi Pembelajaran

| Parameter / Metrik | B1 | B2 | B3 | B4 | B5 |
|---|---|---|---|---|---|
| Trainable Params | 11,181,642 | 5,130 | 8,398,858 | 8,398,858 | 424,970 |
| Total Params | 11,181,642 | 11,181,642 | 11,181,642 | 11,181,642 | 4,020,358 |
| Learning Rate | 1e-3 (All) | 1e-3 (fc) | 1e-4 (layer4), 1e-3 (fc) | 1e-4 (layer4), 1e-3 (fc) | 1e-4 (top stage), 1e-3 (head) |
| Epoch Konvergen | Ep 6 (dari 10) | Ep 22 (dari 24) | Ep 8 (dari 12) | Ep 8 (dari 12) | Ep 16 (dari 20) |
| Durasi (s) | 196.9 | 404.1 | 214.5 | 151.7 | 367.6 |
| Best Val Loss | 1.7334 | 0.1404 | 0.0761 | 0.1120 | 0.1470 |
| Peak Val Acc (%) | 40.94% (Ep 6) | 95.30% (Ep 8) | 97.32% (Ep 8) | 95.97% (Ep 7) | 95.64% (Ep 14) |

Fergio Harjanto - 2802392412

| | | | | | |
|---|---|---|---|---|---|
| Val Acc @ Best Loss (%) | 40.94% | 93.96% | 97.32% | 95.64% | 95.30% |
| Test Acc (%) | 34.45% | 96.66% | 96.99% | 96.32% | 97.32% |
| Test Macro F1 | 0.3259 | 0.9667 | 0.9700 | 0.9634 | 0.9732 |






II. C2 - Pembahasan Analisis Komparatif

A. Disparitas Performa Tajam antara Pelatihan dari Nol (B1) vs. Transfer Learning (B2 & B3) terjadi karena ketika melatih dari nol, kita harus mengoptimasi seluruh parameter pada model ResNet18 (11,181,642 parameter), sehingga membutuhkan volume data training yang sangat besar. Dataset yang kecil menyebabkan model di B1 untuk terjebak di lokal minimum. Jika dibanding dengan transfer learning, model B2 dan B3 sudah dilatih, sehingga proses pelatihan hanya meng-adjust weights yang sudah ada di model.

B. Untuk Trade-off performa dan stabilitas, feature extraction (model B2) hanya melatih 5.130 parameter dibanding model B3 yang melatih 8.398.858 parameter. B2 membutuhkan waktu 404.1 detik dengan full 24 epoch, sementara model B3 hampir 2 × lebih cepat dalam 214.5 detik dengan early stopping pada epoch 12. Pada metrik validation loss dan accuracy, B3 unggul di keduanya (0.0761 vs. 0.1404 pada loss dan 97.32% vs. 95.30% pada accuracy). B3 juga memimpin pada test accuracy dan macro F1-score (96.99% (F1 0.9700) vs. 96.66% (F1 0.9667))

C. Berdasarkan eksperimen B4, tanpa augmentasi, model fine-tuning cepat mengalai memorization, Tanpa augmentasi, model fine-tuning cenderung menghafal bias latar belakang dan orientasi spesifik data training. Dengan menambahkan augmentasi data aktif pada B3 (RandomResizedCrop, RandomHorizontalFlip, RandomRotation 15°, dan ColorJitter), variasi citra latih diperluas secara stokastik, memaksa model mempelajari invarian

visual esensial dan meredam kecenderungan overfitting pada skenario data terbatas.

III. C3 - Failure Analysis (Analisis Kasus Misklasifikasi)

A. Hasil sampel citra dari test set yang salah diprediksi menunjukkan bahwa semua sampel yang salah berasal dari class kucing. Hal ini dapat disebabkan arena ras-ras anjing bisa sangat berbeda dari yang liannya, sedangkan ras-ras kucing hanya memiliki perbedaan unik yang lebih sedikit. Anjing dapat memiliki perbedaan pada ukuran, bentuk mancung, bentuk ekor, tebal bulu, serta warna dan pola bulu nya, sedangkan kucing rerata memiliki fitur-fitur anatomi yang mirip, sehingga perbedaan yang paling mencolok ada di warna bulu, mata, dan pola bulu. Akibat itu; varians pada hal seperti:
   1. Distorsi pada warna foto
   2. Oklusi
   3. Pencahayaan yang buruk

   Akan lebih fatal pada prediksi model. Hasil per-sample ada di file ipynb (akibat keterbatasan page di laporan)
   https://www.livescience.com/59875-less-variety-in-cats-than-dogs.html

IV. C4 - Rekomendasi Rekayasa dan Batasan Eksperimen
Rekomendasi

A. Gunakan EfficientNet-B0 untuk efisiensi yang lebih besar. Jika dibandingkan dengan ResNet-18, EfficientNet lebih hemat parameter, sambil mencapai nilai akurasi dan f1 tertinggi.
B. Gunakan domain-aware data augmentation. Berdasarkan eksperimen B4, data tanpa augmentasi akan lebih cepat menyebabkan memorization. Terapkan augmentasi yang menjaga invariansi semantik (RandomResizedCrop, Flip, Rotasi $\pm 15^\circ$, ColorJitter ringan), dan hindari augmentasi yang merusak penanda biologis ras (seperti pembalikan vertikal 180°).
C. Untuk dataset terbatas (seperti dataset ini), jangan melatih model dari awal (feature extraction), melainkan terapkan fine tuning. Strategi ini terbukti memangkas waktu konvergensi (214.5 detik vs 404.1 detik pada B2) sekaligus menghasilkan akurasi yang lebih tinggi (96.99%).

Batasan

A. Seluruh eksperimen dilakukan dalam 1 seed, yang menjamin reproducibility, namun akan lebih rentan terhadap varians performa pada seed lainnya.
B. Eksperimen hanya menggunakan subset 10 class, yang dimana dataset menyediakan 37 class. Hasil model dapat berubah secara signifikan jika semua class diimplementasikan
C. Eksperimen memiliki batasan compute, hanya menggunakan GPU T4 gratis dari Google Colab, yang rentan disconnect akibat demand.

V. C5 - Eksplorasi Tambahan (Nilai Tambah / Opsional)

A. Sebelum fine tuning (model B2), peta attention lebih menyebar luas (lingkaran attention pada pred-beagle lebih besar, lebih mencakup fitur-fitur diluar Beagle). Hal ini menunjukkan weight bawaan ImageNet yang ditrain menggunakan lebih dari 20.000 objek class, sehingga mendeteksi objek-objek diluar target.
B. Setelah fine tuning (model B3), peta attention lebih mengarah dan memusat pada hewan-hewan target (contohnya, pada british shorthair, attention tertinggi warna merah lebih besar, pada beagle, lingkaran lebih kecil dan terfokus pada beagle nya sendiri)